



AGENCE CONGOLAISE POUR L'EMPLOI

Rapport Technique : Système Intelligent d'Appariement Demandeurs et Offreurs d'Emploi Solution IA Explicable et Opérationnelle pour l'ACPE

Stanislas Mboundou Mangoubi, MSc. Actuariat

Email : stanislasaigle@gmail.com

Hackathon IndabaX Congo 2026

Juillet 2026

Résumé

Ce rapport présente la conception technique du moteur d'appariement intelligent développé par l'équipe S2M pour l'Agence Congolaise pour l'Emploi (ACPE). Face à un volume critique de données (41 285 demandeurs pour 2 535 offres), notre solution implémente une approche hybride unissant la similarité textuelle vectorielle (TF-IDF Cosinus) à des règles métiers déterministes. Conforme aux exigences du jury, ce système se distingue par son explicabilité totale (XAI) terme à terme, son équité algorithmique native, sa capacité d'analyse d'écart de compétences (*skill gap*) et un tableau de bord d'aide à la décision entièrement interactif et filtrable raccordé à un pipeline d'harmonisation catégorielle stricte. Le choix du TF-IDF n'est pas un choix par défaut : il est validé empiriquement contre une alternative à base d'embeddings BERT, qu'il surpasse nettement sur nos données tout en garantissant une étanchéité sémantique face aux faux positifs.

1 Contexte et Problématique

L'Agence Congolaise pour l'Emploi (ACPE) occupe une position stratégique dans la régulation du marché du travail en République du Congo. Cependant, l'identification des meilleures correspondances entre les profils des demandeurs et les exigences des entreprises repose historiquement sur un traitement essentiellement manuel et chronophage. À l'ère de la science des données, l'absence d'un outil d'aide à la décision automatisé limite la réactivité des conseillers et la valorisation des informations collectées.

L'enjeu de ce projet est de concevoir un prototype logiciel capable de calculer un score de compatibilité transparent, de générer des recommandations optimales de type Top- K (Top-5 et Top-10), et de fournir une interface opérationnelle immédiate sans nécessiter d'infrastructures de calcul lourdes ou coûteuses.

2 Pipeline de Données et Préparation

L'intégration et la réconciliation des quatre bases de données fournies s'effectuent au sein d'un pipeline unifié (`src/data_loader.py`). Le tableau 1 résume les volumes et la structure après nettoyage complet.

TABLE 1 – Structure et volumétrie des bases de données réconciliées

Fichier Source	Identifiant Clef	Volume	Rôle dans le Pipeline
Demandeurs.xlsx	Matricule	41 285	Profils textuels des demandeurs
Offres_ACPE.xlsx	Référence offre	2 535	Table de référence des offres
Offres_ACPE_Extensions.xlsx	Référence	143	Enrichissement textuel libre
Appariement_Demandeurs_Offres.xlsx	id_demandeur	41 285	Vérité terrain (<i>Ground Truth</i>)

2.1 Décisions de Nettoyage et Alignement Structurant

- **Normalisation Syntaxique** : Les en-têtes contenant des espaces parasites ou des accents (ex : « offre_pertinente ») ont été systématiquement nettoyés pour éviter les échecs silencieux d'indexation.
- **Fusion Textuelle par Complétude** : Une analyse de cardinalité a prouvé que les 143 lignes du fichier d'extension ne couvraient pas de nouvelles offres mais un enrichissement sémantique d'offres déjà existantes dans la table principale ; elles ont donc été fusionnées par jointure gauche.
- **Traitement des Sentinelles** : La chaîne « Non déclaré », omniprésente dans les données (~ 91% pour le champ Secteur demandé), est traitée explicitement comme une valeur manquante (NaN) afin de ne pas biaiser la fréquence des termes du modèle.

2.2 Standardisation et Harmonisation Catégorielle Visuelle

Afin de pallier les scories des données brutes (doublons de casse, variantes de genre et fragmentation) sans altérer le texte source qui alimente les vectorizers du moteur de production, un sous-pipeline d'harmonisation dérive des colonnes dédiées à l'affichage (`_std`) :

- **Niveau d'étude et Métiers** : La variable `niveau_etude` est nettoyée en place (`MAJ + strip`) pour fusionner « Aucun/aucun/AUCUN ». Les colonnes `metier_std` et `qualification_metier_std` regroupent les genres (ex : « Étudiant/Étudiante » fusionnent sous l'étiquette unique **Étudiant(e)**).
- **statut_demandeur** : Une segmentation explicite sépare les profils en trois catégories nettes : *Professionnels en activité* (39 441), *Étudiant(e)s* (1 804), et *Stagiaires* (40).
- **Consolidation Sectorielle** : Un dictionnaire de correspondance fusionne les étiquettes de secteurs redondantes ou morcelées. Les trois variantes d'Agriculture sont ainsi consolidées sous l'étiquette unique **Agriculture & Agroalimentaire** au niveau du filtre interactif et des graphiques du tableau de bord.

2.3 Simulation Déterministe de la Position Géographique

Le fichier initial des demandeurs ne présentant aucune variable de localisation exploitable, nous avons généré une variable synthétique de localité candidate sans altérer les fichiers sources. Afin d'assurer le réalisme du prototype, le tirage respecte strictement la distribution probabiliste réelle des offres (Lieu), concentrant ainsi les candidats simulés sur les bassins d'emploi effectifs (Brazzaville, Pointe-Noire, etc.).

La reproductibilité est garantie par un hachage déterministe basé sur le Matricule du candidat. Cette variable simulée demeure un artefact analytique dédié aux fonctionnalités visuelles (carte du tableau de bord, filtres de recherche recruteur) et n'entre jamais dans le calcul du score d'appariement pur.

3 Architecture du Moteur d'Appariement

Pour répondre simultanément aux critères de performance algorithmique (30% de la note) et d'explicabilité, nous avons implémenté un modèle hybride combinant le traitement automatique du langage naturel (NLP) et des contraintes métiers.

3.1 Modélisation Mathématique et Sécurisation Algorithmique

Le score brut d'appariement entre un candidat c et une offre o est défini par l'équation linéaire suivante :

$$Score_{raw}(c, o) = w_t \cdot Sim_{cos}(v_c, v_o) + w_m \cdot Recouvrement(M_c, I_o) \quad (1)$$

Où v_c et v_o représentent les vecteurs TF-IDF du candidat et de l'offre, calculés sur un espace de n -grammes de longueur 1 à 2 (`ngram_range=(1,2)`), filtrant les termes apparaissant moins de deux fois (`min_df=2`). Sim_{cos} désigne la similarité cosinus mesurant l'alignement directionnel des profils :

$$Sim_{cos}(v_c, v_o) = \frac{v_c \cdot v_o}{\|v_c\| \|v_o\|} \quad (2)$$

$Recouvrement(M_c, I_o)$ mesure l'intersection normalisée des tokens entre le Métier visé (M_c) et l'Intitulé de l'offre (I_o), agissant comme un amplificateur de précision pour les correspondances exactes de poste. Les poids empiriques sont fixés à $w_t = 0,80$ et $w_m = 0,20$.

Durcissement Anti-Faux Positifs (Garde d'Intersection Stricte) : Pour contrer le phénomène de pollution sémantique dans les onglets de recherche interactive (ex : une recherche "*Femme de ménage*" qui remonterait indûment un profil d'"*Assistant de direction*" suite à des termes transversaux diffus présents en description), une condition d'intersection logique stricte (**AND**) a été intégrée dans `search_offers` et `search_candidates`. Si la requête ne partage aucun jeton (*token*) en commun avec le cœur professionnel de la cible (Intitulé / Poste / Secteur), l'offre est immédiatement rejetée sous le seuil d'affichage minimal (`MIN_COMPATIBILITY = 45`). De plus, le paramètre `substring=False` a été configuré dans l'analyseur lexical afin de limiter la recherche aux strictes flexions grammaticales (ex : *gestion* → *gestionnaire*) en bloquant les sous-chaînes fortuites au milieu d'un mot (comme *menage* au sein du terme *aménamenagement*).

Correction de la fuite logistique : La fonction d'activation originale projetait indûment un score brut nul (orthogonalité totale des vecteurs, soit aucun token en commun) vers une valeur positive de $\approx 23,1\%$. Pour éliminer ces faux positifs, nous imposons une condition stricte aux limites $Compatibilité(0) = 0$, rendant la calibration continue en zéro tout en préservant la monotonie du classement :

$$Compatibilité(\%) = \begin{cases} 0 & \text{si } Score_{raw} \leq 0, \\ \frac{100}{1 + e^{-8 \cdot (Score_{raw} - 0,15)}} & \text{si } Score_{raw} > 0 \end{cases} \quad (3)$$

Le friture de mobilité géographique nationale a également été durci en intersection stricte (**AND**), assurant un retour de tableau vide propre si aucun profil ne valide la contrainte.

3.2 Justification Scientifique face aux Modèles Alternatifs

Le choix de l'architecture hybride TF-IDF + Règles Métiers résulte d'un arbitrage rigoureux. Les approches par règles pures (couverture médiocre due aux divergences taxonomiques) et par Learning-to-Rank supervisé (risque de surapprentissage par manque de négatifs explicites) ont été écartées d'emblée.

L'alternative des modèles de Deep Learning sémantiques (*Sentence-BERT*) a fait l'objet d'une évaluation empirique rigoureuse hors-ligne sur un échantillon représentatif de 4 000 demandeurs, en utilisant le modèle `paraphrase-multilingual-MiniLM-L12-v2` (384 dimensions).

Le verdict du Tableau 2 est sans appel : le modèle TF-IDF surclasse nettement BERT sur l'ensemble des métriques. De plus, la performance de l'hybride décroît de façon monotone à mesure que le poids de l'embedding sémantique (α étant le poids du TF-IDF) augmente. Notre architecture hybride S2M s'impose ainsi comme l'option scientifiquement optimale.

TABLE 2 – Benchmark empirique des moteurs d'appariement (échantillon $N = 4\,000$)

Moteur	P@5	P@10	R@5	R@10	NDCG@5	NDCG@10
TF-IDF (déployé)	0,423	0,256	0,704	0,852	0,680	0,748
BERT (MiniLM)	0,185	0,125	0,308	0,415	0,279	0,328
Hybride $\alpha = 0,3$	0,319	0,195	0,532	0,651	0,532	0,586
Hybride $\alpha = 0,5$	0,354	0,216	0,590	0,720	0,595	0,655
Hybride $\alpha = 0,7$	0,374	0,227	0,623	0,757	0,622	0,683

4 Ingénierie de l'Explicabilité (XAI) et Équité

Conformément aux orientations du jury, l'explicabilité n'est pas une surcouche mais un pilier natif de l'algorithme :

1. **Décomposition des Composantes** : Chaque conseiller ACPE voit la contribution exacte de la sémantique (80%) et de la règle métier (20%).
2. **Extraction des Termes Déterminants** : La similarité cosinus étant une somme de contributions terme à terme, notre module `src/explain.py` isole et affiche les mots exacts (ex : *transit*, *logistique*) ayant provoqué la décision.
3. **Équité par Conception (Fairness)** : Les variables sensibles telles que l'âge et le genre sont explicitement exclues de la fonction de score. L'équité est totale, auditable et garantie par l'architecture du code.

5 Résultats et Métriques d'Évaluation

Le moteur a été évalué de manière exhaustive sur l'ensemble de la population de test (41 285 demandeurs) via le script batch `scripts/generate_recommendations.py`. Les formules appliquées respectent les consignes officielles :

$$Precision@K = \frac{|O_{recommandées} \cap O_{pertinentes}|}{K}, \quad Recall@K = \frac{|O_{recommandées} \cap O_{pertinentes}|}{|O_{totales_pertinentes}|} \quad (4)$$

Le tableau 3 présente les performances globales obtenues, validées après intégration des gardes strictes.

TABLE 3 – Performances globales validées face à la vérité terrain de l'ACPE

Seuil d'Évaluation (K)	Precision@K	Recall@K	NDCG@K
Top-5 Recommandations	0,427	0,712	0,688
Top-10 Recommandations	0,257	0,855	0,753

Analyse des performances : La vérité terrain limitant structurellement le nombre d'offres pertinentes à 3 par candidat, la Precision@5 maximale théorique est mathématiquement plafonnée à $3/5 = 0,60$. Notre score de 0,427 atteint ainsi 71,2% du maximum théorique possible. Le Recall@10 de 0,855 garantit que dans plus de 85% des cas, les conseillers trouvent l'offre idéale dans les 10 premières options suggérées par l'IA. Par construction, les fonctions de sécurisation n'ont altéré en rien les performances pures du moteur batch, garantissant une exécution complète et fluide en seulement 50,7 secondes.

5.1 Analyse de la supériorité du modèle TF-IDF sur BERT

La sous-performance de BERT (P@5 de 0,185 contre 0,423 pour TF-IDF) et la dégradation monotone de l'hybride s'expliquent rigoureusement par trois facteurs structurels :

1. **Anisotropie et pénurie de contexte** : Les modèles de type SBERT exploitent l'auto-attention sur des phrases construites. Nos données étant composées d'intitulés très courts (2 à 4 mots), l'espace dense souffre d'anisotropie, ce qui effondre son pouvoir discriminant. Le TF-IDF, via la pondération IDF (Inverse Document Frequency), maximise à l'inverse la spécificité de ces tokens courts et rares.
2. **Décalage de domaine (Hors-Distribution)** : Le modèle MiniLM pré-entraîné sur des corpus web généralistes ne maîtrise pas la taxonomie spécifique du marché de l'emploi congolais. Ce décalage provoque un phénomène de *semantic smearing*, rapprochant à tort des rôles fonctionnellement distincts. Le TF-IDF estime son IDF directement sur le corpus de l'ACPE, assurant un alignement parfait avec le domaine.
3. **Nature de la vérité terrain** : L'appariement de référence historique de l'ACPE repose sur un alignement rigoureusement lexical (métier $\leftrightarrow$ intitulé). Les n -grammes du TF-IDF capturent ce signal de manière optimale, tandis que la généralisation conceptuelle de BERT génère du bruit vis-à-vis des attentes de validation.

6 Fonctionnalités Bonus et Exploitation Directe

Le prototype intègre pleinement les défis avancés requis pour transformer l'expérience utilisateur :

- **Recherche Intelligente en Langage Naturel (Bonus 1)** : Un double moteur permet des requêtes libres sur les offres et les candidats, avec détection automatique de la localité au sein de la phrase et tolérance aux variations grammaticales par analyse de préfixes, durci par la contrainte AND anti-faux positifs.
- **Analyse des Écarts de Compétences (Bonus 2)** : Le système extrait dynamiquement les exigences manquantes (ex : *Git*, *Power BI*) pour orienter le citoyen vers des formations ciblées.
- **Tableau de Bord Décisionnel Interactif (Dashboard)** : Développé aux couleurs nationales, il intègre une carte KPI dédiée au **Statut des demandeurs d'emploi** (isolant étudiants/stagiaires). Le graphique des métiers les plus demandés s'appuie sur la colonne épurée `metier_std`. Enfin, une section visuelle croise le top des secteurs consolidés (`secteur_std`) par type de contrat (**CDI en vert / CDD en jaune**).

7 Conclusion

La solution portée démontre qu'il est possible d'allier une haute précision mathématique à une transparence totale indispensable pour une agence publique. Le choix du TF-IDF, loin d'être un compromis, est empiriquement démontré supérieur aux embeddings profonds sur ce type de données. Léger, déterministe, sans dépendance matérielle lourde et immédiatement exploitable, ce prototype pose les fondations d'une intermédiation moderne, robuste et équitable pour l'emploi en République du Congo.

8 Bibliographie Sélective

Références

- [1] Ribeiro, M. T., Singh, S., et Guestrin, C. (2016). "Why should I trust you ?" : *Explaining the predictions of any classifier*. Proceedings of the ACM SIGKDD.
- [2] Ethayarajh, K. (2019). *How contextual are contextualized word representations ? Comparing the geometry of BERT, ELMo, and GPT-2 embeddings*. EMNLP-IJCNLP.
- [3] Reimers, N., et Gurevych, I. (2019). *Sentence-BERT : Sentence embeddings using Siamese BERT-networks*. EMNLP-IJCNLP.